

論文選定の方針

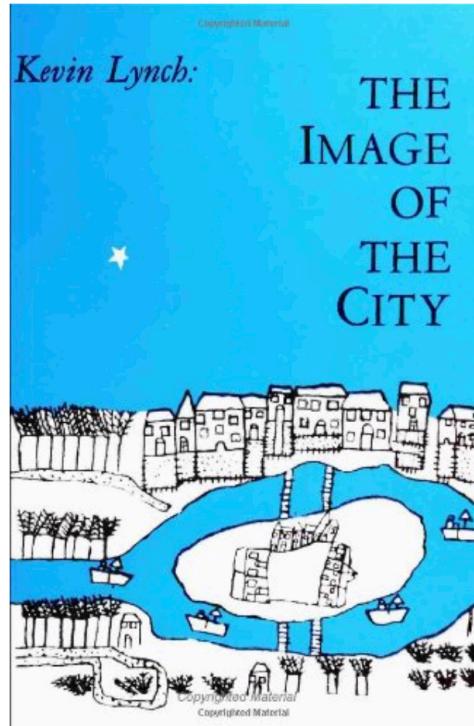
- 一つの技術を深掘りして読む
- 影響力のある論文を読む
- 周辺技術も含め、ある程度浅く広く読んで傾向をつかむ

今回はこちら

とはいえ、広いAI海をどう渡っていけば良いか…

(手がかり 1) 修士時代：都市イメージと計画論の接続

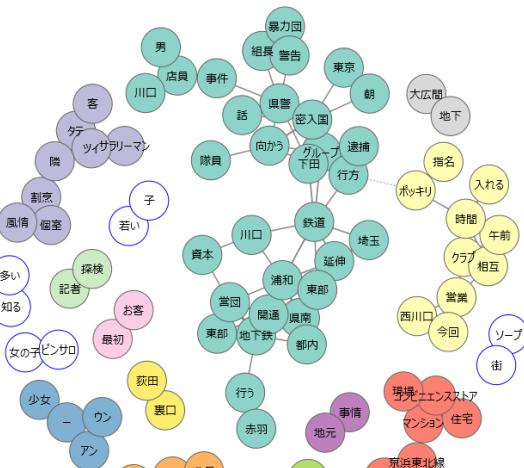
長らく、「都市のアイデンティティ」から意味の領域が意図的に除かれてきた。



「もしわれわれの目的が、さまざまな背景をもつ無数の人々の喜びのための都市、そして将来の目的にかなう都市をつくることにあるならば、イメージの物理的な明瞭さに集中して、意味の方はわれわれの直接の指導なしに展開させる方が賢明であると言えるだろう（邦訳p. 9）



言語的なアプローチを用いて意味の領域を関連づけることで計画論に組み込む。



西川口のイメージ研究 (新聞・雑誌+現地)

- 計量テキスト分析
 - ディスコース分析
 - 現象学的考察
 - 計画への実装

(研究期間：2010~2013)

この時の課題として

- ・計量する際の恣意性排除が難問（当時はまだ研究が少なかった）
 - ・図、写真、イラストを計量的に分析できない

(手がかり 2) 最近の都市界隈のトレンド

会話情報学では…

- 人間社会が人工知能のもたらすベネフィットを最大限に享受できるようにするためには、人間社会と人工知能がともに依拠できる「**共通基盤（Common Ground）**」を構築し、発展させていくことが不可欠。（西田豊明, 2018）

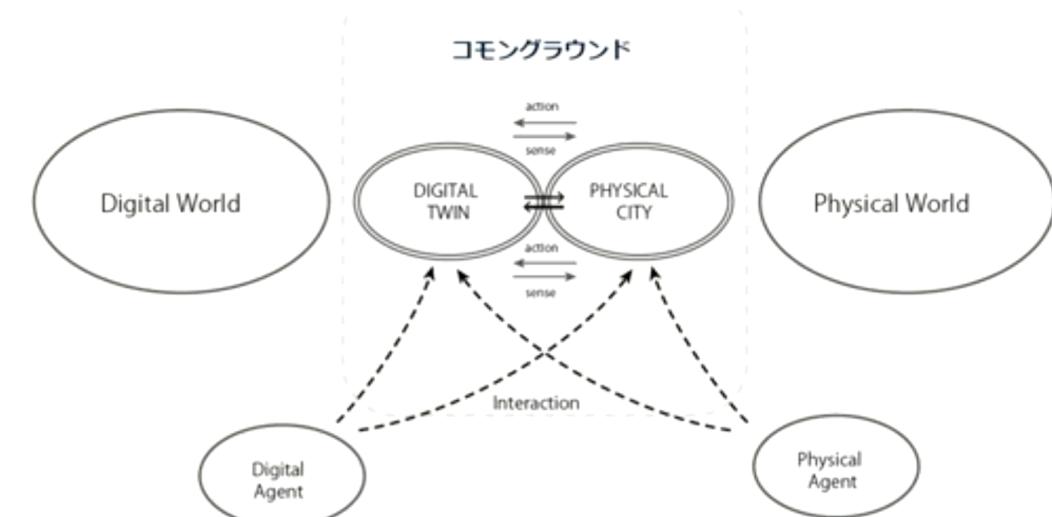


- 都市のマルチバース化（豊田啓介, 2019）

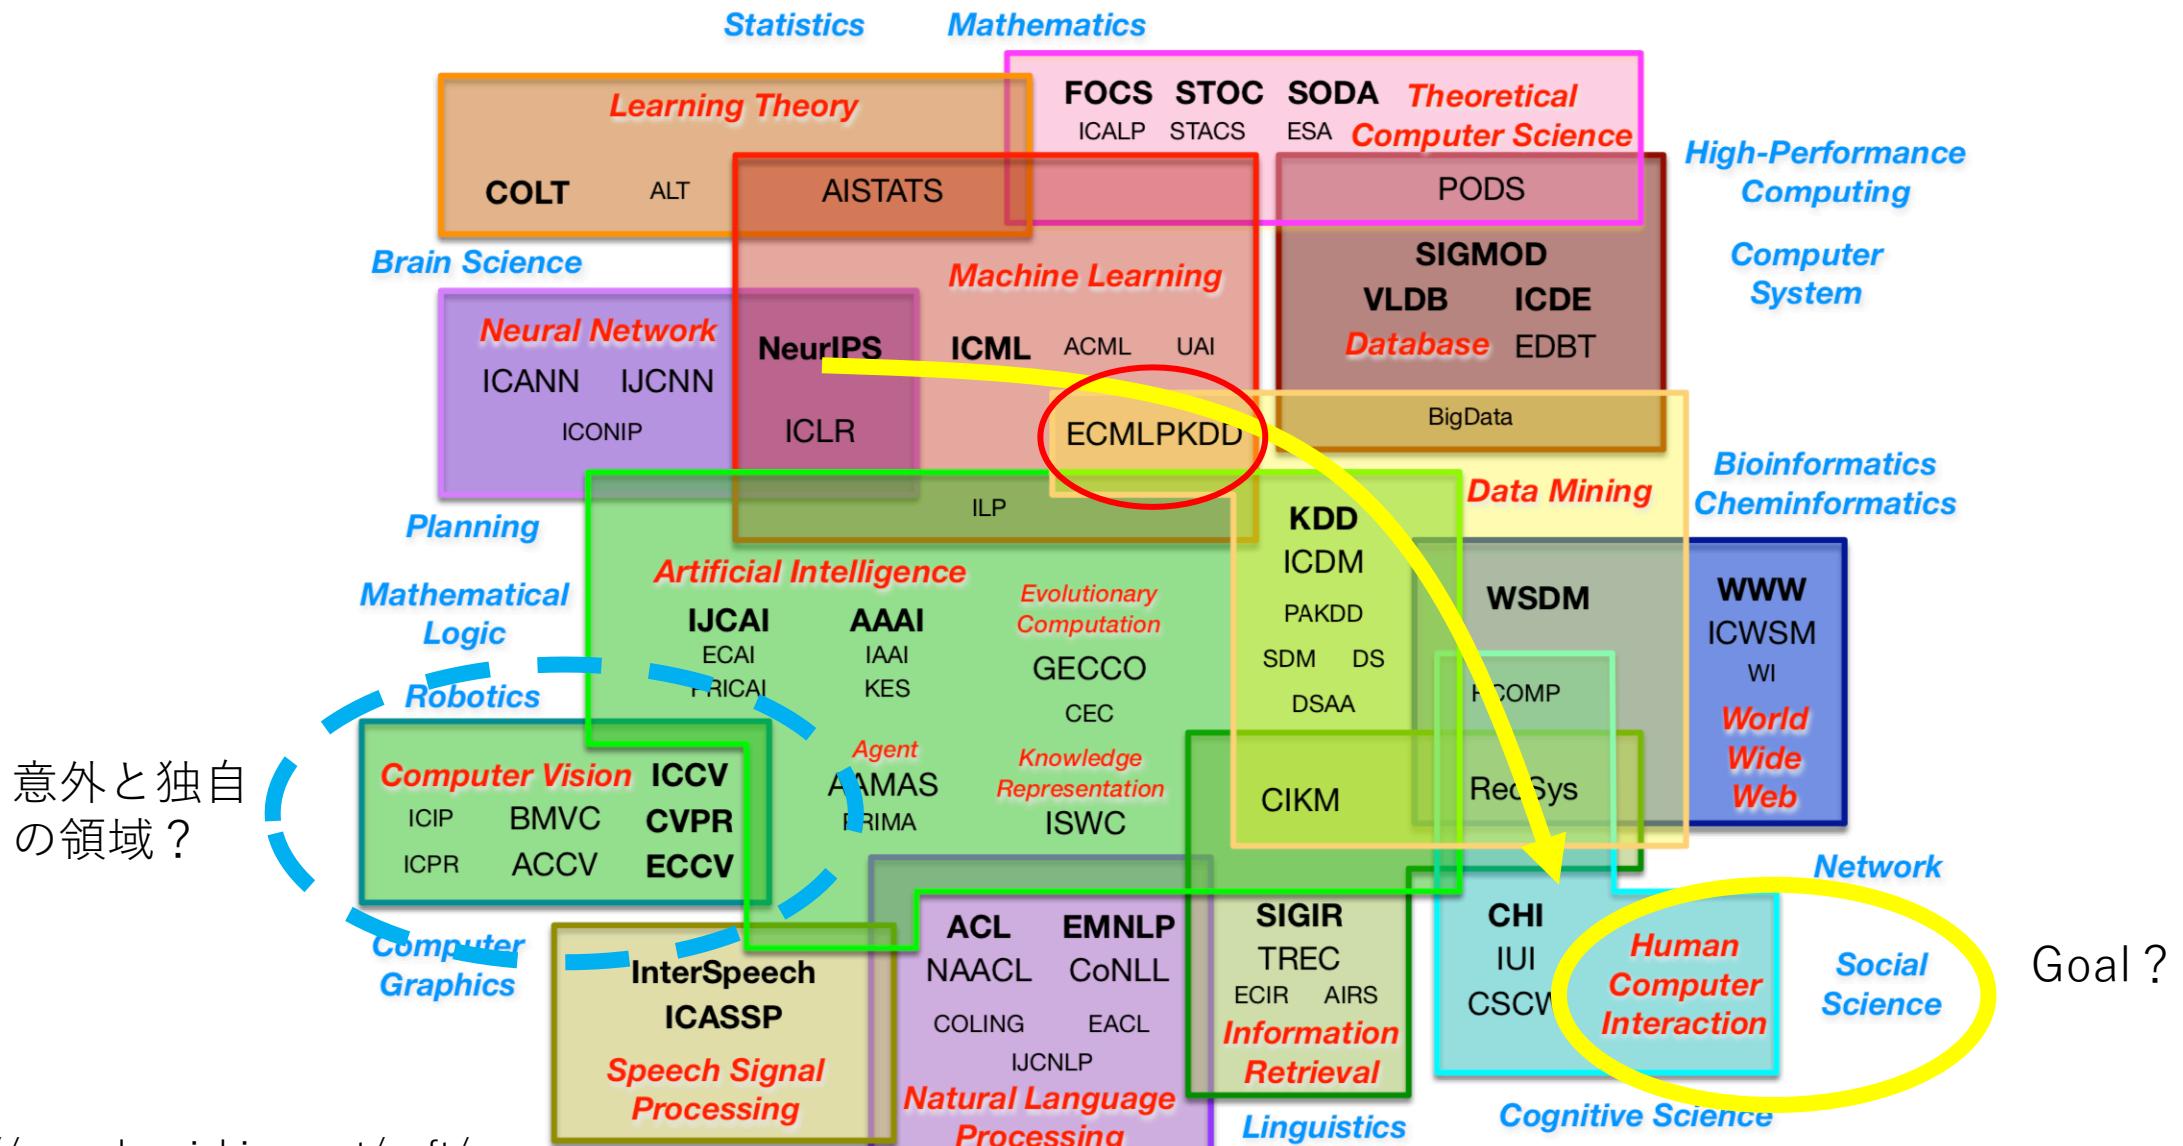
建築・都市領域のコモングラウンドを形成する

=デジタルエージェント（AI）からも、
物理エージェント（人間）からも
認識可能な世界記述の準汎用体系

INNOVATIVE CITY FORUM 2019 基調講演
「都市のマルチバース化とコモングラウンドという新大陸」より



重なりを頼りに道筋をつけてみる



ECML PKDD2019(9月開催)のAcceptedの中でさらに分野を絞り込む

<Research> () は論文数

- Deep Learning (15)
- Supervised Learning (11)
- Reinforcement Learning & Bandits (12)
- Multi-Label Learning (5)
- Large-Scale Learning (3)
- Natural Language Processing (6)
- Probabilistic Models (10)
- Decision Trees/Interpretability/Causality (5)
- Optimization & Learning Theory (6)
- Dimensionality Reduction & Feature Selection (4)
- Social Networks & Graphs (15)
- Clustering (6)
- Clustering, Anomaly & Outlier Detection (6)
- Autoencoder and Clustering (4)
- Privacy & Security (3)
- Pattern Mining (4)
- Strings and Streams (6)
- Ranking (5)

<Applied Data Science> real world use cases

- ADS: Computer Vision & Explanation (5)
- ADS: E-Commerce, Finance, Advertising (5)
- ADS: Healthcare (5)
- ADS: Applications (8)
- ADS: Rich Data (5)

論文数が多い (=活発?) のと、
自身の得意分野 (社会科学) に近そう

Social Networks & Graphsの中で、これまで学んできた機械学習と関連の高そうなものを優先して読む

<NNモデル使用論文>

- Triangle Completion Time Prediction using Time-conserving Embedding
- SoRecGAT: Leveraging Graph Attention Mechanism for Top-N Social Recommendation

<クラス分類>

- Node Representation Learning for Directed Graphs
- Node Classification for Signed Social Networks Using Diffuse Interface Methods
- Link Prediction via Higher-Order Motif Features

<クラスタリング>

- User-Guided Clustering in Heterogeneous Information Networks via Motif-Based Comprehensive Transcription

<CNN>

- Learning Aligned-Spatial Graph Convolutional Networks for Graph Classification



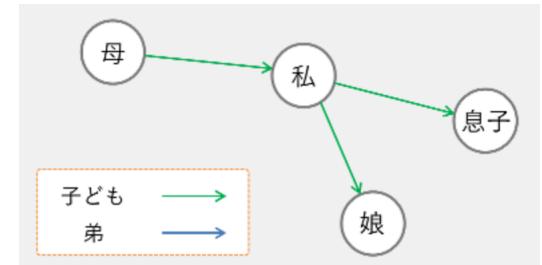
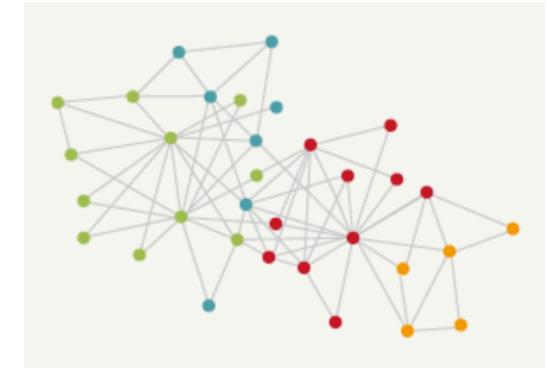
CNNキタ！

Graph Convolutional Networks (2017)

- グラフ構造を畳み込むネットワーク
- 画像はいかなる場合でも周囲の近傍画素は8画素であるが、グラフ構造における**近傍ノード**というのはデータ毎に変わってくる。
- 入力は**グラフ構造を持ったデータ**
出力は**データの特徴量**
- 過去、化学物質の構造に対して適用されることが多かったが、
顧客の行動予測であったり、 Webデータの分析や量子化学の研究、交通・物流の分析、3D空間上のタスクに応用が期待

<GCNの文脈>

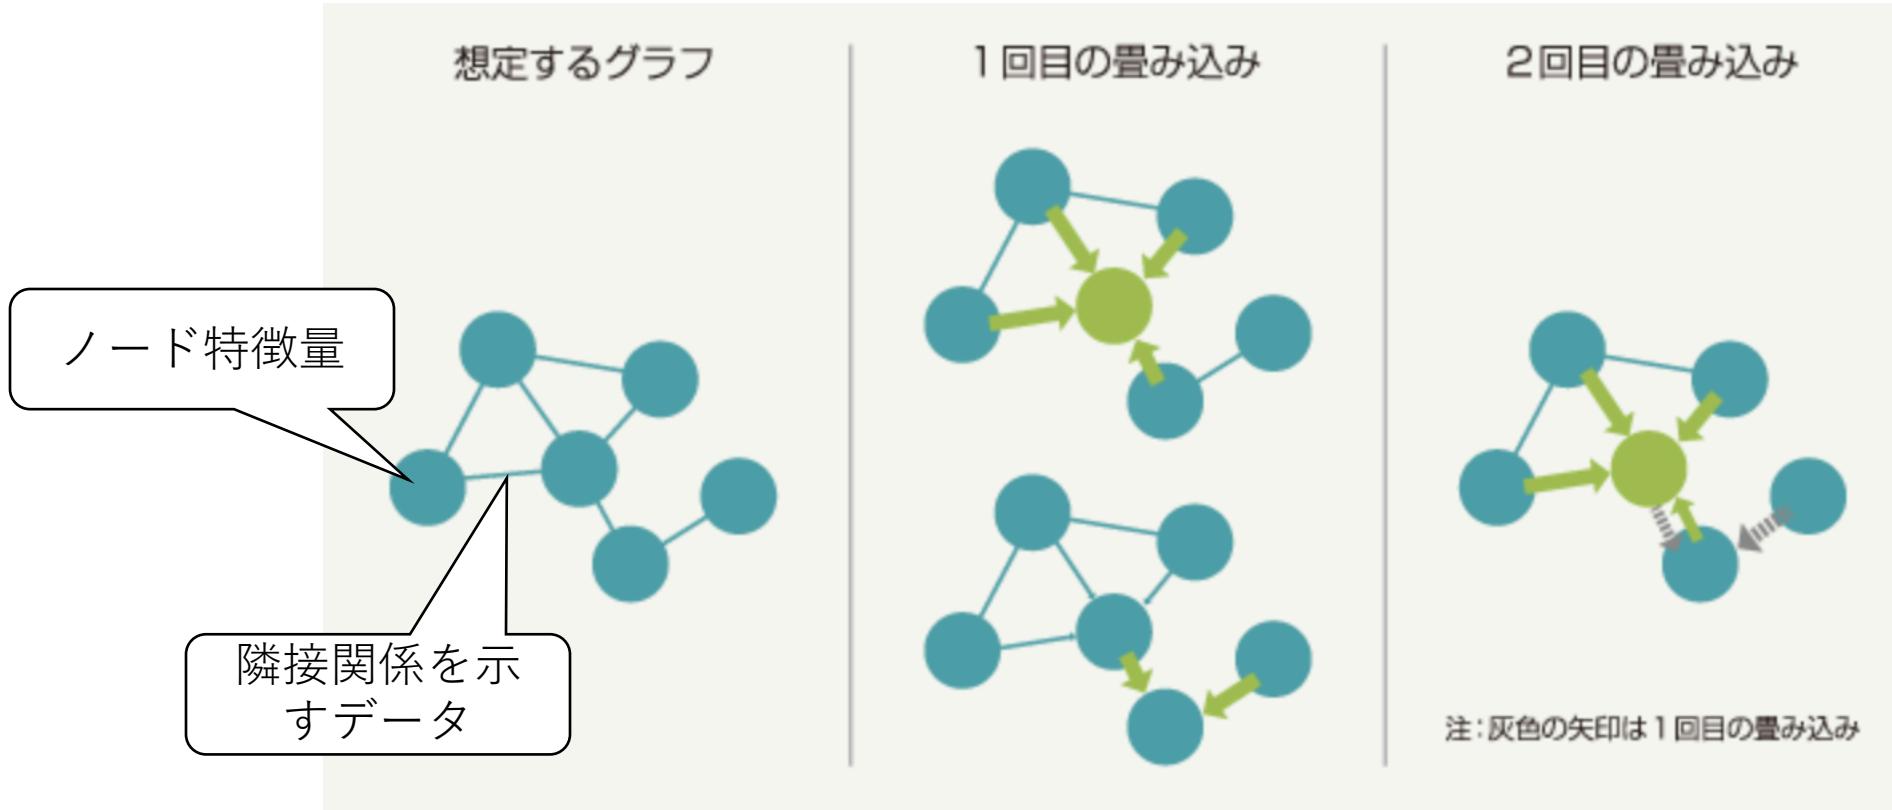
- Spectral graph theoryとSpatial Strategiesが主流派



$$L_{child_in} = W_{child_in} v_{mother}$$

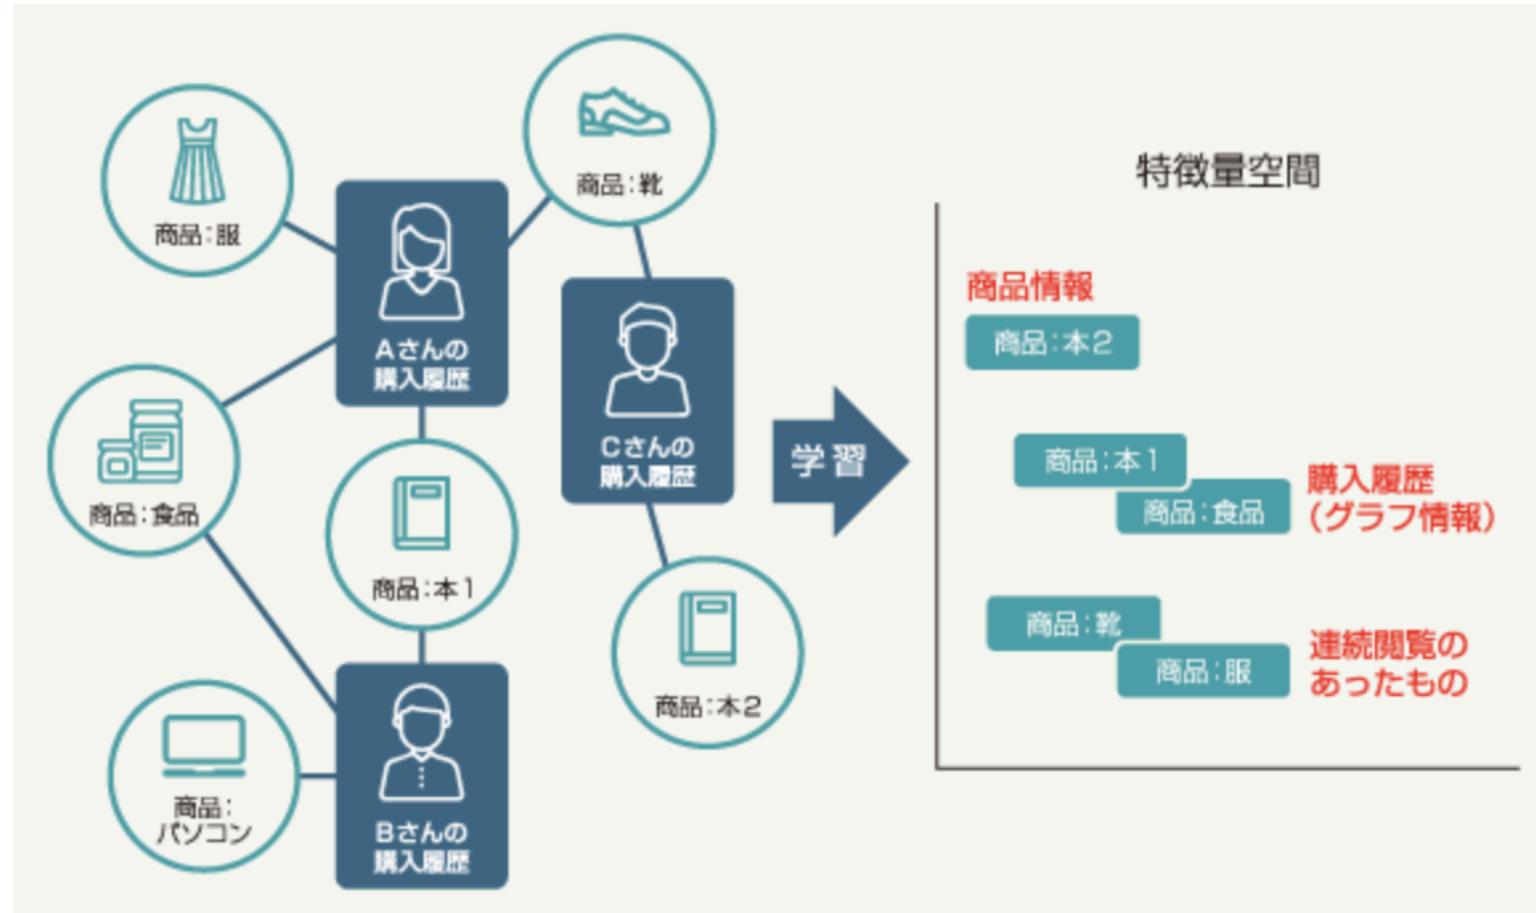
$$L_{child_out} = W_{child_out} v_{son} + W_{child_out} v_{daughter}$$

GCNの畳み込みとは



ターゲットノードが持っている特徴量に
(隣接ノードの特徴量 × 重み) を加えていく

レコメンデーションでの応用

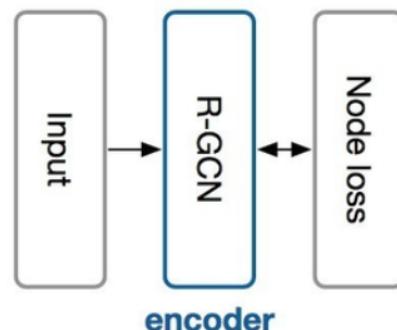


画像や説明などからわかる商品自体の特徴と、ユーザーの購入履歴とを考慮した商品の特徴量を獲得し、連続して閲覧されることの多い商品同士は特徴量空間上で近づくように、そうでない商品同士は離れるように畳み込みの重みを学習することでレコメンドの指標を得る

知識ベース補完 (knowledge base completion)

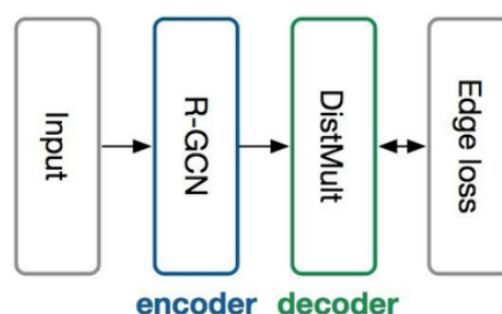
- エッジ予測 (link prediction)
欠損したエッジを予測する (図の 1)
グラフオートエンコーダーモデルを用い, エンコーダーとして R-GCN を使い,
デコーダーとして DistMult というモデルを用いる。

- ノード分類 (entity classification)
ノードのラベルを分類する (図の 2)
R-GCN の層をいくつか重ね, 最終層で softmax 関数にかけるという操作をしており, 入力されたノードの特徴量ベクトルからそのノードのクラスを予想



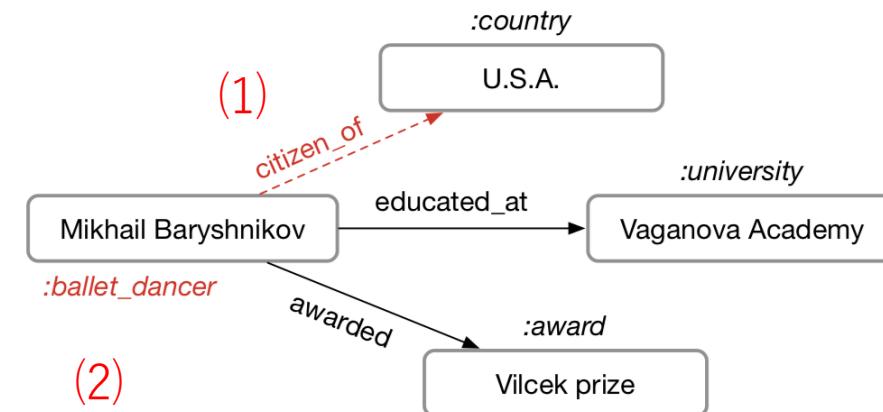
(b) Entity classification model

ノード分類



(c) Link prediction model

エッジ予測



古典手法：Spectral Clustering

- グラフの隣接行列を固有値分解する手法。
- フーリエ級数と固有値ベクトル分解は等価であるため、グラフを信号に見立てたときのFourie展開で計算が可能。
- 固有値で役立つのは上位数個 (d) のため、常に上位 d を取るとすると定型サイズのフィルタを段々と適用するCNNのような形になる。

GCNの課題

- Kipf & Wellingの提案したGraph Convolutional Networks (GCN)は学習されたフィルタがグラフランプシアンの固有ベクトルに依存するため**異なるグラフ構造に対応することができない**。そこでフィルタがグラフ構造に依存しないような方法があると良い。

Attention機能

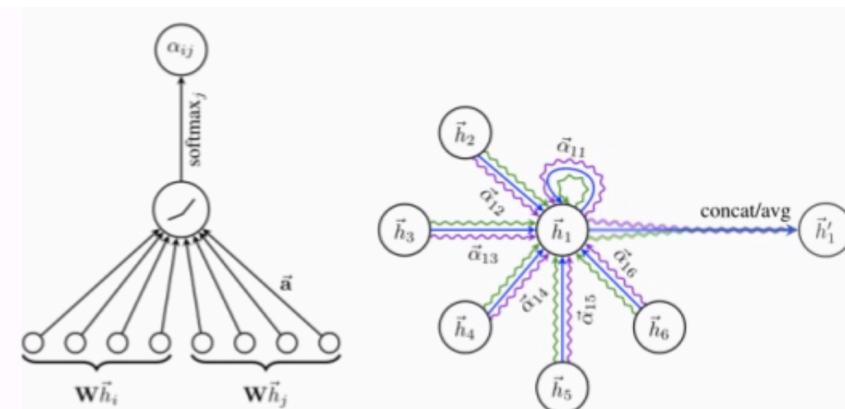
異なるグラフに対応

Graph Attention Networks (2018)

- グラフ構造においては、NodeだけでなくEdgeの情報も重要。ただ、Edgeの潜在表現を作っていると計算速度が遅くなる。
- そこで、Edgeの情報をAttentionの重みとして表現することで、Edgeの情報を取ることができ、計算速度もそこそこを維持できる。
- Attentionは、自身のノードと、その周辺ノードにそれぞれ重みを掛けて結合したベクトルをもとに算出される。
- フィルタがK枚ある場合は、K個の重みをそれぞれについてAttentionとforwardの計算を行い、平均をとる。

$$\alpha_{ij} = \frac{\exp \left(\text{LeakyReLU} \left(\vec{a}^T [\mathbf{W}\vec{h}_i \| \mathbf{W}\vec{h}_j] \right) \right)}{\sum_{k \in \mathcal{N}_i} \exp \left(\text{LeakyReLU} \left(\vec{a}^T [\mathbf{W}\vec{h}_i \| \mathbf{W}\vec{h}_k] \right) \right)}$$

$$\vec{h}'_i = \sigma \left(\frac{1}{K} \sum_{k=1}^K \sum_{j \in \mathcal{N}_i} \alpha_{ij}^k \mathbf{W}^k \vec{h}_j \right)$$



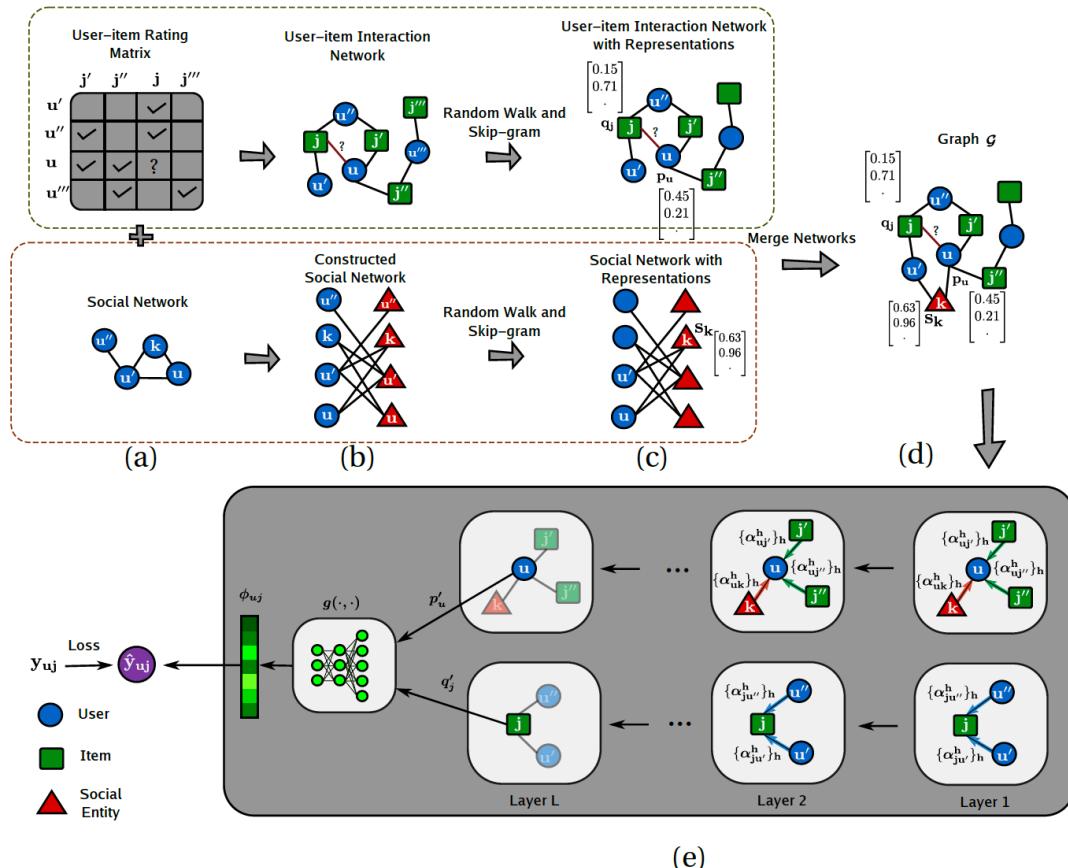
SoRecGAT: Leveraging Graph AttentionMechanism for Top-N Social Recommendation

Vijaikumar , Shirish Shevade (2019)

<https://ecmlpkdd2019.org/downloads/paper/475.pdf>

どんなもの？

これまでのレコメンデーションでは、隣接関係のあるユーザは全て平等に扱われていたが、現実に即してないので、ユーザとユーザ、ユーザとアイテムの暗黙的な関係を加味した新手法としてSoRecGATを提案。



技術の手法や肝は？

マルチヘッド (multi-head)かつマルチレイヤなグラフアテンション機構を採用し、Social networkやuser-item interaction networkなどが混交したネットワークを構成することで、学習時にノード間の影響をよりよく把握することができた

どうやって有効だと検証した？

Amazon、Yelp それぞれ4つのデータセットを使用し、既存のモデルと比較することで、新手法の有効性を検証した。

議論はある？

Attention headsは有効だが、multi-headとして[12,6]サイズを超えると過学習が起こる。

先行研究と比べて何がすごい？

これまでのレコメンデーションでは、隣接関係のあるユーザは全て平等に扱われていたが、現実に即してないので、ユーザとユーザ、ユーザとアイテムの暗黙的な関係を加味して、スコアを改善することができた。

次に読むべき論文は？

- Graph Attention Networks(Petar Veličković, 2018) 被用件数 : 760
- Leveraging Meta-path based Context for Top-N Recommendation with A Neural Co-Attention Model (Binbin Hu , 2018) 被用件数 : 55
- Graph Neural Networks for Social Recommendation(Wenqi Fan , 2019)被用件数 : 15

SoRecGAT: Leveraging Graph AttentionMechanism for Top-N Social Recommendation

Vijaikumar , Shirish Shevade (2019)

<https://ecmlpkdd2019.org/downloads/paper/475.pdf>

どんなもの？

空間ベースGCNの新しい手法として、Aligned-SpatialGraphConvolutional Networkと呼ばれるクラス分類手法を開発。任意サイズのグラフ構造を固定サイズのグリッド構造に変換する

技術の手法や肝は？

- ・情報ロスなく、グラフのリサイズに成功（どんなサイズのグラフにも対応可）
- ・情報ロスなく、グラフの畳み込みに成功

どうやって有効だと検証した？

Bioinformatics系、Social系のデータセットを使用

議論はある？

記述

先行研究と比べて何がすごい？

グラフの情報ロス問題や既存のGCNで生じていた不正確な特徴量抽出を緩和させるだけでなく、CNNとGCN間にあった論理的飛躍を架橋することに成功した。

次に読むべき論文は？

- Semi-Supervised Classification with Graph Convolutional Networks(Kipf, 2017) : 被引用数 2277
- Modeling Relational Data with Graph Convolutional Networks (M Schlichtkrull, 2017) 被引用数 : 334

